

Analyse de données: Parcoursup 2025

Accès à l'enseignement supérieur en France

Corentin Brandam Augustin Traissac Romain Deleris

INSA Toulouse, 4GMM 2025–2026

Plan de la présentation

Contexte et données

Analyse univariée

Analyse bivariée

Analyse exploratoire et Clustering

Conclusion et synthèse

1

Contexte et données

Introduction

Enjeux et problématique de l'orientation

Le dispositif Parcoursup

Plateforme nationale pivot pour l'accès à l'enseignement supérieur.

- **Centralisation** unique des candidatures.
- **Régulation** des flux d'étudiants.
- **Transparence** via l'Open Data national.

Problématique d'analyse

Dans quelle mesure la typologie des formations (sélectivité, filière, géographie) influence-t-elle les profils des admis et l'équilibre du système ?

14 252+

Formations répertoriées

900 000+


Candidats annuels

118

Variables analysées

Prétraitement des données

Du fichier brut aux variables d'analyse



Objectif : transformer une base brute redondante en variables synthétiques et interprétables.


2

Analyse univariée

Analyse univariée

Distributions des variables


Variables qualitatives



Lecture

Les établissements publics représentent presque 80% des formations.

Variables quantitatives



Lecture

Le pourcentage de boursiers admis est distribué autour de 20 %.

Analyse univariée


Distributions des variables

	pct_filles	pct_boursiers	taux_acces	pression	pct_meme_academie
count	14252.0	14252.0	13076.0	14248.0	14252.0
mean	50.0	22.27	58.3	21.1	69.53
std	29.62	17.77	29.37	33.52	28.77
min	0.0	0.0	1.0	0.05	0.0
25%	25.0	9.0	33.0	6.17	52.0
50%	53.0	20.0	58.0	11.42	78.0
75%	75.0	32.0	86.0	23.5	93.0
max	100.0	100.0	100.0	904.67	100.0

Lecture

Autant de filles que de garçons sont admis dans une formation sur Parcoursup.
Le taux d'accès frole les 60 % et presque 70 % des admis sont issus de la même académie.

Fréquences par filière de formation



Lecture

Les BTS représentent 37 % des formations présentes.
Modalité "Autre formation" très présente et compliquée à interpréter.

Lecture globale

Les filières de formation se concentrent dans les grandes villes étudiantes (Paris, Toulouse, Bordeaux, Lille...). Les formations plus rurales sont moins sélectives.


Présence d'outliers géographiques (DOM-TOM, antennes à l'étranger), avec un faible taux d'accès en général.

3

Analyse bivariable


Analyse bivarée

Matrice de corrélation des variables créées



Analyse bidimensionnelle

Région et ancrage local



Lecture

Pour chaque région, on observe la répartition des formations selon leur degré d'ancrage local.


Résultat

Les régions comportant des grandes villes étudiantes, attractives au niveau national, se distinguent par une proportion plus élevée de formations à faible ancrage local.

Les régions plus rurales ont des formations avec un rayonnement plus local.

Analyse bidimensionnelle

Taux d'accès selon les filières



Lecture

Pour chaque filière, on observe la répartition du taux d'accès de chaque établissement.


Résultat

Taux d'accès très hétérogène au sein de certaines filières (licences, écoles d'ingénieur, BTS...).

Filières de santé (IFSI, PASS) plus sélectives de manière générale.


Limites : certaines formations ont des frais de candidature (écoles d'ingénieur/commerce, BTS...).

Analyse bidimensionnelle



Lecture

Filières santé et social majoritairement féminines.
Ecoles d'ingénieur et de commerce majoritairement masculines.




Lecture

Très peu de boursiers dans les formations privées.
Coût des études ? Auto-censure ?


Analyse bidimensionnelle

Formations féminisées et masculinisées

Top 10 formations majoritairement féminines



Top 10 formations majoritairement masculines



Observation : les profils de genre restent fortement liés au type de filière.


Analyse bidimensionnelle

Présence des boursiers selon les filières

Top 10 formations avec beaucoup de boursiers



Top 10 formations avec peu de boursiers




Observation : l'origine sociale semble aussi différencier les profils de formation. Les boursiers s'orientent plutôt vers des formations courtes et professionnalisantes que des prépas, écoles d'ingénieurs ou de commerce.

Analyse en composantes principales


4

Analyse en composantes principales



Lecture

Les 3 premiers axes expliquent 47.3 % de la variance totale, pas suffisant pour bien interpréter tout le jeu de données.





Lecture

Axe 1 = filières générales d'excellence académique, à faible taux d'accès.
Axe 2 = établissements à fort effectif, plutôt féminins.

Analyse en composantes principales


Projection des individus



Observation : le premier axe différencie bien les filières professionnalisantes des filières plus générales et académiques.

Clustering sur ACP

Segmentation des formations dans l'espace factoriel



K-means

Partitionnement par minimisation de l'inertie **intra-classe**.

Méthode rapide, adaptée aux groupes **compacts et sphériques** dans l'espace de l'ACP.

CAH

Classification **Ascendante** Hiérarchique (critère de Ward).




Fusion progressive des groupes pour maximiser l'homogénéité locale.

GMM

Modèles de mélange gaussiens (*Gaussian Mixture Models*).

Approche probabiliste permettant de capturer des amas aux formes **ellipsoïdales**.

Comparaison des méthodes Synthèse et validation



Validation

Les partitions sont validées via :

- Score de silhouette ;
- Calinski-Harabasz ;
- Tables de contingence.

Synthèse des pôles

Trois profils types émergent :

- 1 **Professionalisant**
- 2 **Généraliste** / Volumineux
- 3 **Sélectif** / Académique

Interprétation


Le clustering prolonge l'ACP : la structure observée n'est pas un dû au hasard mais à une organisation réelle et robuste du dataset.

5

Analyse des correspondances multiples

ACM

Espace qualitatif commun



Données

13 954 formations, 10 variables qualitatives : filière, statut, sélectivité, pression, accès, boursiers, féminisation.

Axes



Axe 1 : filière, profil admis, sélectivité.

Axe 2 : pression, accès, mentions.

Inertie

Les 5 premiers axes résument environ 31.65% de l'inertie totale.

Clustering sur ACM K-means, ACH et GMM



K-means

3 clusters.

Groupes compacts autour de centres.

ACH

3 clusters.

Regroupement hiérarchique avec Ward.

GMM


3 clusters.

Mélange gaussien, formes elliptiques.

Idée clé : les méthodes retrouvent des pôles proches : BTS/professionnel, licences, formations sélectives.

Comparaison des partitions

Scores et tables de contingence





Conclusion

K-means obtient les meilleurs scores internes, mais GMM produit une partition très proche. Les différentes méthodes retrouvent donc une structure globale cohérente et relativement robuste.

Méthodes complémentaires

Méthodes complémentaires

Analyses exploratoires



Spectral Clustering

Partitionnement basé sur la connectivité du graphe.

- Identifie **4 segments** distincts.
- Structures non convexes.

Paramétrage DBSCAN

Analyse de la *k-distance* pour fixer le rayon ϵ .

- Seuil de densité optimale (le « coude »).
- Isole le bruit des zones denses.

Approximation SBM

Modélisation par blocs stochastiques.


- Regroupement simplifié en **3 clusters**.
- Probabilité de liaison réseau.

7

Conclusion et synthèse

Conclusion et synthèse

Trois grands profils de formations



Lecture globale

Les différentes méthodes de clustering retrouvent une organisation de l'espace Parcoursup autour de trois grands profils de formations.

Conclusion et synthèse

Profils des admis

Lecture globale

Les différentes analyses mettent en évidence des disparités sur les profils admis dans certaines formations (lycée général/techno/pro, genre, niveau de revenu, origine géographique...).

Résultats principaux

Les filles s'orientent plus vers des filières santé, social et littéraires et moins vers des prépas et autres formations scientifiques.

Les boursiers choisissent des formations courtes et professionnalisantes, alors que les études d'ingénieurs ou de commerce leurs restent majoritairement fermées.

Questions soulevées

Quelles sont les causes de ces inégalités ?
Biais de l'algorithme de sélection ? Coût des études ? Autocensure ? Coût de la mobilité ?
Stéréotypes de genre ? Accès à l'information inégal ?

Robustesse des résultats

K-means, ACH et GMM produisent des partitions proches :

- mêmes grands profils de formations ;
- organisation globale stable ;
- cohérence entre ACP/ACM et clustering.

Limites

- Les clusters restent des profils-types.
- Certaines formations restent proches des frontières.
- Le nombre de groupes dépend du choix méthodologique.



Merci pour votre attention

Avez-vous des questions ?

Augustin Traissac

·

Corentin Brandam

·

Romain Deleris